

Отчет по результатам выполнения заданий практикума

Студент: Михельсон В.В. 316

9 декабря 2025 г.

Содержание

1	Описание Датасета	8
2	Теория ядерных оценок	9
3	Реализация и результаты	10
4	Выводы по данным распределения характеристик вина	12
4.1	Качество вина	12
4.2	Содержание алкоголя	12
4.3	Летучая кислотность	12
4.4	Остаточный сахар	13
4.5	Общие выводы	13
5	Анализ данных с использованием различных графиков	13
5.1	Зависимость качества вина и алкогольной крепости	13
5.2	Dotchart	15
5.3	Boxplot и Stripchart	17
5.4	Сравнение графиков, построенных на Python и R	20
6	Проверка выбросов с использованием тестов Граббса и Q-теста Диксона	20
6.1	Теоретические основы	20
6.1.1	Q-тест Диксона	21
6.1.2	Тест Граббса	21
7	Обоснование выбора параметра летучей кислотности	22
8	Результаты проверки выбросов	23
8.1	Результаты теста Граббса	23
8.2	Результаты Q-теста Диксона	23
8.3	Заключение	24
9	Методы восстановления пропусков в данных	24
9.1	Описание методов	24
9.2	Результаты тестирования	25
9.3	Визуализация восстановления пропусков	25
9.4	Сравнение результатов между Python и R	27

10 Анализ данных с помощью графиков эмпирических функций распределений	27
10.1 Графики эмпирических функций распределений (ECDF) .	27
10.1.1 Особенности ECDF	28
10.2 Данные для анализа	28
10.3 Визуализация ECDF	29
10.4 Графики квантиль-квантиль (Q-Q Plots)	30
10.4.1 Описание метода	30
10.4.2 Применение Q-Q Plots	31
10.5 Заключение	32
10.6 Метод огибающих	32
10.6.1 Теоретические основы	32
10.6.2 Анализ данных с помощью огибающих	32
10.6.3 Выводы и сравнение Python и R	34
10.6.4 Заключение	34
11 Критерии проверки нормальности данных	34
11.1 Тест Шапиро-Уилка (и Шапиро-Франсиса)	34
11.2 Тест Андерсона-Дарлинга	35
11.3 Критерий Крамера-фон Мизеса	36
11.4 Тест Колмогорова-Смирнова	37
11.5 Модификация Лиллиефорса теста Колмогорова-Смирнова .	38
11.6 Заключение	39
12 Сравнение результатов проверки нормальности между Python и R	40
12.1 Сводные результаты тестов	40
12.2 Выводы по результатам сравнения Python и R	40
13 Анализ реальных данных на нормальность	41
13.1 Графики эмпирической функции распределения (ECDF) .	42
13.2 Графики квантиль-квантиль (Q-Q Plots)	43
13.3 Графики огибающих	44
13.4 Различия между Python и R	45
13.5 Анализ нормальности данных	46
13.6 Заключение	46

14 Проверка гипотез о средних значениях выборок с использованием критерия Стьюдента	47
14.1 Теоретические основы	47
14.1.1 Нулевая и альтернативная гипотезы	47
14.1.2 Основные формулы	47
14.1.3 Условия применимости	48
14.1.4 Типы тестов	48
14.1.5 Правило принятия решения	49
14.2 Описание теста	49
14.3 Результаты тестов	49
14.4 Сравнение результатов Python и R	50
14.5 Выводы	50
15 Проверка гипотезы с использованием U-теста Манна-Уитни	51
15.1 Теоретические основы	51
15.1.1 Нулевая и альтернативная гипотезы	51
15.1.2 Основные формулы	51
15.1.3 Условия применимости	52
15.1.4 Типы тестов	52
15.1.5 Правило принятия решения	52
15.2 Описание анализа	53
15.3 Результаты тестов	53
15.4 Сравнение Python и R	53
15.5 Выводы	54
16 Проверка гипотез об однородности дисперсий с использованием различных критериев	54
16.1 Теоретические основы	54
16.1.1 Нулевая и альтернативная гипотезы	55
16.1.2 Основные критерии и их формулы	55
16.1.3 Условия применимости и особенности	56
16.1.4 Правило принятия решения	57
16.2 Результаты тестов	57
16.2.1 Сравнение выборок с равными дисперсиями	57
16.2.2 Сравнение выборок с различными дисперсиями	58
16.3 Сравнение реализаций в Python и R	58
16.4 Выводы	59

17	Корреляционные взаимосвязи в данных о качестве вина	59
17.1	Теоретические основы	59
17.1.1	Нулевая и альтернативная гипотезы	60
17.1.2	Основные коэффициенты и их формулы	60
17.1.3	Условия применимости и особенности	61
17.1.4	Интерпретация значений коэффициентов	61
17.1.5	Правило принятия решения	62
17.2	Результаты корреляционного анализа	62
17.2.1	Результаты Python	62
17.2.2	Результаты R	62
17.3	Сравнение результатов Python и R	63
17.4	Выводы	64
18	Различные методы анализа данных	65
18.1	Критерий хи-квадрат	65
18.1.1	Основные гипотезы	65
18.1.2	Формула	65
18.1.3	Применимость	65
18.2	Точный тест Фишера	65
18.2.1	Основные гипотезы	66
18.2.2	Особенности	66
18.3	Тест МакНемара	66
18.3.1	Основные гипотезы	66
18.3.2	Формула	66
18.3.3	Применимость	66
18.4	Тест Кохрана-Мантеля-Хензеля	67
18.4.1	Основные гипотезы	67
18.4.2	Формула	67
18.4.3	Применимость	67
18.5	Проверка зависимости между содержанием алкоголя и ле- тучей кислотностью с использованием критерия хи-квадрат	67
18.5.1	Описание исследования	67
18.5.2	Результаты теста	68
18.5.3	Выводы	68
18.6	Проверка зависимости между качеством вина и остаточ- ным сахаром с использованием точного теста Фишера . . .	69
18.6.1	Описание исследования	69
18.6.2	Результаты теста	69

18.6.3	Анализ различий между Python и R	70
18.6.4	Выводы	71
18.7	Проверка зависимости между качеством вина и содержа- нием алкоголя с использованием теста МакНемара	71
18.7.1	Описание исследования	71
18.7.2	Результаты теста	71
18.7.3	Выводы	72
18.8	Стратифицированный анализ связи с использованием те- ста Кохрана-Мантеля-Хензеля	73
18.8.1	Описание исследования	73
18.8.2	Результаты теста	73
18.8.3	Выводы	73
18.9	Общие выводы	73
18.10	Стратифицированный анализ связи между алкоголем и оста- точным сахаром с использованием теста Кохрана-Мантеля- Хензеля	74
18.10.1	Описание исследования	74
18.10.2	Результаты теста	75
18.10.3	Выводы	75
19	Проверка наличия мультиколлинеарности в данных о вине	75
19.1	Методы анализа	75
19.2	Фактор инфляции дисперсии (VIF)	76
19.2.1	Расчёт VIF	76
19.2.2	Интерпретация значений	76
19.2.3	Преимущества и ограничения	76
19.3	Корреляционная матрица	77
19.4	Фактор инфляции дисперсии (VIF)	79
19.5	Анализ результатов	79
19.6	Выводы	80
19.7	Рекомендации	80
20	Анализ влияния содержания алкоголя на физические свой- ства вина	81
20.1	Дисперсионный анализ (ANOVA)	81
20.1.1	Теоретические основы	81
20.1.2	Нулевая и альтернативная гипотезы	81
20.1.3	Основные формулы	81

20.1.4	Условия применимости	82
20.1.5	Интерпретация результатов	82
20.1.6	Описание исследования	83
20.1.7	Модификации ANOVA	83
20.1.8	Результаты теста	83
20.1.9	Выводы	83
21	Аппроксимация данных с использованием регрессионных моделей	84
21.1	Описание исследования	84
21.2	Результаты анализа	85
21.3	Выводы	85
22	Общее сравнение Python и R	86
22.1	Общие наблюдения	86
22.2	Заключение	87
	Список литературы	87

1 Описание Датасета

Анализируемый датасет содержит информацию о 1599 вин, включая их качество, физические характеристики и другие данные. Включенные столбцы предоставляют следующую информацию:

- **fixed acidity**: Нерестурирующая кислотность. Основные кислоты (виннокаменная, яблочная, лимонная), влияющие на кислотность и стабильность вина. Измеряется в г/л.
- **volatile acidity**: Летучая кислотность. Концентрация уксусной кислоты и других летучих кислот. Высокий уровень может приводить к неприятному уксусному запаху и вкусу. Измеряется в г/л.
- **citric acid**: Лимонная кислота. Вторичная кислота, встречающаяся в вине в небольших количествах. Добавляется для повышения кислотности, свежести и аромата. Измеряется в г/л.
- **residual sugar**: Остаточный сахар. Концентрация сахара, оставшегося после остановки брожения. Определяет сладость вина. Измеряется в г/л.
- **chlorides**: Хлориды. Содержание солей в вине, в основном поваренной соли. Влияет на солёность вкуса. Измеряется в г/л.
- **free sulfur dioxide**: Свободный диоксид серы. Концентрация свободной формы SO_2 , которая действует как антимикробный агент и антиоксидант, предотвращая окисление. Измеряется в мг/л.
- **total sulfur dioxide**: Общий диоксид серы. Суммарное количество свободной и связанной форм SO_2 в вине. Измеряется в мг/л.
- **density**: Плотность. Плотность вина, которая в основном зависит от концентрации алкоголя и остаточного сахара. Измеряется в г/мл.
- **pH**: Водородный показатель. Логарифмическая мера концентрации ионов водорода. Определяет кислотность вина по шкале от 0 до 14 (ниже 7 - кислая среда). Безразмерная величина.

- **sulphates:** Сульфаты. Концентрация солей серной кислоты (например, сульфата калия). Могут использоваться как антисептик и влияют на аромат. Измеряется в г/л.
- **alcohol:** Алкоголь. Содержание этилового спирта в вине, обычно выражается в процентах от объёма (% об.). Влияет на полноту вкуса, сладость и текстуру вина.
- **quality:** Качество. Субъективная оценка качества вина, обычно выражается в баллах по определённой шкале (например, от 0 до 10).

На основе статистических характеристик можно выделить следующие ключевые моменты:

- Средняя летучая кислотность равна 0.53 г/л, с диапазоном от 0.12 г/л до 1.58 г/л.
- Среднее значение остаточного сахара равно 2.54 г/л, минимальное значение - 0.90 г/л, максимальное - 15.50 г/л.
- Среднее содержание алкоголя равно 10.42% об., минимальное значение - 8.40% об., максимальное - 14.90% об.
- Средняя оценка качества вина составляет 5.64 балла, минимальная оценка - 3.00 балла, максимальная - 8.00 баллов.

Все данные представлены без пропусков, что значительно упрощает их анализ.

2 Теория ядерных оценок

Ядерные оценки плотности (Kernel Density Estimation, KDE) представляют собой метод, который используется для восстановления неизвестной функции плотности вероятности по данным выборки. Этот подход позволяет получить представление о распределении случайной величины без необходимости задавать его точную форму. В отличие от гистограмм, ядерная оценка обеспечивает более гладкую и точную аппроксимацию распределения.

Выражение для ядерной оценки плотности задается следующим образом:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

где:

- x_i - элементы выборки,
- h - ширина окна сглаживания (параметр сглаживания),
- K - функция ядра (чаще всего используется гауссово ядро).

Применение метода KDE позволяет глубже изучать распределение данных, особенно в случаях, когда данные имеют сложную структуру или не соответствуют стандартным теоретическим распределениям.

3 Реализация и результаты

Для аппроксимации распределений в Python и R были использованы библиотеки, поддерживающие метод KDE. Ниже представлены получившиеся графики KDE.

На рисунке ниже представлены два набора графиков: первый был создан с использованием Python, а второй - с использованием R.




Рис. 1: Графики, построенные на Python.




Рис. 2: Графики, построенные на R.

4 Выводы по данным распределения характеристик вина

4.1 Качество вина

- **Гистограмма:** Распределение качества вина сосредоточено вокруг центральных значений, что указывает на преобладание вин среднего качества в выборке. Большая часть вин имеет оценку качества 5 и 6 баллов.
- **KDE:** Плавная кривая плотности подтверждает, что основная масса вин имеет качество в диапазоне от 5 до 7 баллов, с пиком вокруг значений 5-6.

4.2 Содержание алкоголя

- **Гистограмма:** Распределение крепости вина имеет форму, схожую с нормальным распределением, с некоторым смещением влево. Большинство вин имеют умеренные значения алкоголя в диапазоне 9-12%.
- **KDE:** График плотности показывает аналогичное поведение: наибольшая плотность наблюдается в диапазоне 10–12%, после чего кривая резко падает как в сторону меньших, так и больших значений. Это свидетельствует о том, что более крепкие и слабоалкогольные вина встречаются реже.

4.3 Летучая кислотность

- **Гистограмма:** Распределение летучей кислотности демонстрирует смещение влево, с преобладанием значений в диапазоне 0.4-0.6 г/л. Низкие значения летучей кислотности характерны для качественных вин.
- **KDE:** Плавная кривая плотности подтверждает высокую концентрацию вин с низкой и средней летучей кислотностью, что является положительным фактором для качества вина.

4.4 Остаточный сахар

- **Гистограмма:** Распределение остаточного сахара демонстрирует правую асимметрию, с концентрацией значений в диапазоне 1.5-3 г/л. Такие низкие значения характерны для сухих вин.
- **KDE:** Плавная кривая плотности показывает, что основная масса вин содержит от 2 до 4 грамм остаточного сахара на литр, что соответствует характеристикам сухих вин.

4.5 Общие выводы


- Большая часть вин в выборке имеет среднее и выше среднего качество (5-6 баллов), что характерно для качественных красных вин.
- Преобладают вина со средней алкогольной крепостью (10-12%), что является типичным для сбалансированных вин.
- Низкие значения летучей кислотности и остаточного сахара в основной массе образцов соответствуют характеристикам качественных сухих красных вин.
- Распределения основных параметров свидетельствуют о хорошем качестве выборки и соответствуют ожидаемым характеристикам для данного типа вин.

5 Анализ данных с использованием различных графиков


Для анализа данных были использованы различные графические методы. Рассмотрим взаимосвязь между качеством вина и его крепостью.

5.1 Зависимость качества вина и алкогольной крепости

График демонстрирует связь между качеством вина и его крепостью. Качество вина - это комплексная характеристика, отражающая степень соответствия вина установленным стандартам. Чем больше качество вина, тем больше алкогольная крепость.



(а) График, построенный с использованием Python



(б) График, построенный с использованием R

Рис. 3: Графики качества вина от алкогольной крепости, построенные с использованием Python и R.

Основные выводы:

- **Прямая зависимость между содержанием алкоголя и качеством:** Вина более высокого качества (6-8 баллов) демонстрируют смещение распределения в сторону более высокого содержания алкоголя (11-14%), что указывает на важность достаточной крепости для формирования полнотелого вкуса.
- **Различия в распределении алкоголя по уровням качества:** Для низких оценок качества (3-4 балла) характерно равномерное распределение по всему диапазону алкоголя, в то время как высокие оценки (7-8 баллов) концентрируются в области повышенных значений (12-14%).
- **Чёткое разделение между низкими и высокими качествами:** Распределения для качеств 7-8 баллов визуальнo отделяются от распределений для низких качеств, образуя отдельные "горбы" в области высокого содержания алкоголя.

Заключение:

Анализ распределения подтверждает существование оптимального диапазона содержания алкоголя (12-14%) для получения высоких оценок качества вина, в то время как низкокачественные вина равновероятно встречаются при любой крепости.

5.2 Dotchart

Dotchart (точечная диаграмма) используется для анализа взаимосвязи числовых данных. На рисунках представлены графики, отображающие зависимость между содержанием остаточного сахара и алкогольной крепостью вина. Остаточный сахар характеризует сладость вина: чем выше его содержание, тем более сладким является вино.




Рис. 4: График построенный с использованием Python.



Рис. 5: График построенный с использованием R.

Вывод:

На графиках видна слабая обратная связь между содержанием остаточного сахара и алкогольной крепостью вина. Это указывает на то, что более крепкие вина обычно содержат меньше остаточного сахара, что характерно для сухих вин. Однако распределение точек показывает значительный разброс, что свидетельствует о разнообразии стилей вин -

существуют как сладкие крепкие вина, так и сухие вина с умеренной алкогоельностью.


5.3 Boxplot и Stripchart

Для анализа зависимости между качеством вина и его летучей кислотностью были использованы два вида графиков: Boxplot (диаграмма размаха) и Stripchart (точечная диаграмма). Boxplot визуализирует распределение данных по квартилям, медиану и выбросы, а Stripchart показывает индивидуальные точки данных, что позволяет детализировать анализ.


Boxplot (диаграмма размаха):

На графике Boxplot видна чёткая обратная зависимость между качеством вина и содержанием летучей кислотности. Вина с более высокими оценками качества (6-8 баллов) демонстрируют значительно более низкие значения летучей кислотности (в основном ниже 0.6 г/л), в то время как низкокачественные вина (3-4 балла) имеют широкий разброс значений с заметно более высокой медианной кислотностью.

Медианное значение летучей кислотности последовательно снижается с увеличением балла качества, что подтверждает важность контроля этого параметра для производства качественного вина. Наибольший разброс значений наблюдается у вин среднего качества (5 баллов), что может указывать на нестабильность технологического процесса.



(a) Boxplot, построенный с использованием Python




(b) Boxplot, построенный с использованием R

Рис. 6: Boxplot зависимости летучей кислотности от качества вина.

Stripchart (точечная диаграмма):

График Stripchart визуализирует индивидуальные значения летучей кислотности для каждого вина в зависимости от его качества. Из графика видна чёткая тенденция: с повышением балла качества вина концентрация точек смещается в область более низких значений летучей кислотности. Вина с оценкой 8 баллов имеют исключительно низкие значения кислотности (в основном ниже 0.5 г/л), в то время как вина с низкими оценками (3-4 балла) демонстрируют широкий разброс с многочисленными

ными выбросами в область высоких значений.



(a) Stripchart, построенный с использованием Python



(b) Stripchart, построенный с использованием R

Рис. 7: Stripchart зависимости летучей кислотности от качества вина.

Выводы:

- Существует обратная зависимость между качеством вина и содержанием летучей кислотности: чем выше качество, тем ниже кислотность.

- Высококачественные вина (7-8 баллов) характеризуются стабильно низкими значениями летучей кислотности (0.2-0.5 г/л).
- Низкокачественные вина (3-4 балла) имеют значительный разброс значений с тенденцией к повышенной кислотности.
- Наличие многочисленных выбросов среди вин среднего качества свидетельствует о нестабильности технологического процесса.
- Контроль летучей кислотности является критически важным фактором для достижения высокого качества вина.

5.4 Сравнение графиков, построенных на Python и R

Графики, построенные с использованием Python и R, демонстрируют практически идентичные результаты при анализе данных. Это объясняется использованием одинаковых алгоритмов обработки данных и расчета статистик, таких как медиана, квартильные значения и выбросы в Boxplot, а также точек данных в Stripchart.

Поскольку оба языка программирования используют одни и те же математические подходы, результаты анализа остаются идентичными. Незначительные отличия могут возникать только из-за особенностей внутренних реализаций библиотек, однако они не влияют на выводы. Таким образом, выбор между Python и R для данного анализа не влияет на интерпретацию данных, и оба инструмента предоставляют надежные и корректные результаты.

6 Проверка выбросов с использованием тестов Граббса и Q-теста Диксона

6.1 Теоретические основы

Для обнаружения выбросов в данных применяются различные статистические методы. В данном случае использованы два подхода: Q-тест Диксона и тест Граббса.

6.1.1 Q-тест Диксона

Q-тест Диксона (Dixon's Q test) - это непараметрический тест, который применяется для обнаружения выбросов в небольших выборках (обычно менее 30 наблюдений). Метод направлен на выявление экстремальных значений, как максимальных, так и минимальных, и проверяет их на принадлежность к генеральной совокупности.

Статистика Q рассчитывается по формуле:

$$Q = \frac{x_{\text{ext}} - x_n}{x_{\text{max}} - x_{\text{min}}}$$

где:

- x_{ext} - подозрительное экстремальное значение (минимальное или максимальное);
- x_n - ближайшее соседнее значение к подозрительному экстремальному значению;
- x_{max} и x_{min} - максимальное и минимальное значения выборки соответственно.

Если рассчитанное значение Q превышает критическое значение для выбранного уровня значимости, то подозрительное значение считается выбросом. Важно отметить, что Q-тест Диксона особенно полезен для анализа малых выборок и может применяться даже в случаях, когда выборка не строго нормальна.

6.1.2 Тест Граббса

Тест Граббса (Grubbs' test), также известный как экстремальный тест, представляет собой мощный метод для обнаружения выбросов в одномерных данных. Этот тест направлен на проверку гипотезы о том, что наиболее экстремальное значение в выборке является выбросом, предполагая, что данные следуют нормальному распределению.

Гипотезы теста Граббса формулируются следующим образом:

- **Нулевая гипотеза (H_0):** Все наблюдения принадлежат одной и той же генеральной совокупности, выбросов нет.

- **Альтернативная гипотеза (H_1):** Одно из наблюдений является выбросом.

Тест вычисляет статистику Граббса (G), которая определяется по формуле:

$$G = \frac{\max |x_i - \bar{x}|}{s}$$

где:

- x_i - подозрительное значение, которое проверяется на выброс;
- $\bar{x}$ - среднее арифметическое выборки;
- s - стандартное отклонение выборки.

Если рассчитанное значение статистики Граббса превышает критическое значение для данного уровня значимости, то наблюдение считается выбросом. Этот тест особенно эффективен для небольших и средних выборок, когда требуется выявить одиночный выброс.

7 Обоснование выбора параметра летучей кислотности

Для анализа выбрана величина летучей кислотности (г/л), так как предварительный анализ показал, что её распределение наиболее близко к нормальному среди всех параметров в наборе данных. Это является важным условием для корректного применения тестов Граббса и Диксона, которые требуют, чтобы данные имели нормальное распределение.

Выбор величины летучей кислотности также обусловлен её значимостью для характеристики вина: она позволяет оценить качество и стабильность вина, поскольку высокое содержание летучих кислот может указывать на дефекты брожения и негативно влиять на органолептические свойства. Проверка данных на наличие выбросов с использованием указанных методов помогает повысить точность анализа, обеспечивая устранение искажений, вызванных экстремальными значениями.

8 Результаты проверки выбросов

8.1 Результаты теста Граббса

В результате применения теста Граббса к летучей кислотности были выявлены следующие объекты, которые можно считать выбросами:

№	Летучая кислотность (г/л)	Качество	Алкоголь (%)	Сахар (г)
126	1.33	5	10.9	1.7
127	1.33	5	10.9	1.8
672	1.24	5	9.5	2.0
1299	1.58	3	10.9	2.1

Таблица 1: Выбросы, выявленные с помощью теста Граббса.

Эти объекты имеют значения летучей кислотности, которые значительно отличаются от среднего по выборке, что позволяет классифицировать их как выбросы. Среди выбросов выделяются вина с экстремально высокими значениями летучей кислотности (1.24-1.58 г/л), что значительно превышает типичный диапазон для качественных вин. Особенно выделяется объект №1299 с максимальным значением 1.58 г/л при низком качестве (3 балла), что может указывать на возможные дефекты брожения или нарушения технологии производства.

8.2 Результаты Q-теста Диксона

Применение Q-теста Диксона к 30 наибольшим значениям летучей кислотности выявило наличие выброса. Наибольшее значение (1.58 г/л) было признано выбросом согласно критерию теста.

При дальнейшем анализе подвыборки, исключаящей этот экстремальный выброс (значения с 31-го по 2-е по величине), Q-тест не показал наличия дополнительных выбросов. Это свидетельствует о том, что среди оставшихся высоких значений летучей кислотности распределение является статистически однородным.

Среди 30 наименьших значений летучей кислотности выбросов обнаружено не было, что указывает на равномерность распределения в области низких значений данного параметра.

8.3 Заключение

Анализ показал, что тест Граббса эффективно идентифицировал выбросы среди образцов вина, выделив вина с экстремально высокими значениями летучей кислотности. Тест Диксона выявил один выброс среди 30 наибольших значений летучей кислотности (1.58 г/л), в то время как среди наименьших значений выбросы отсутствуют. Совокупное использование обоих методов позволяет улучшить качество данных и устранить возможные искажения, вызванные аномальными значениями, что особенно важно для последующего анализа взаимосвязей между параметрами вина.

9 Методы восстановления пропусков в данных

Восстановление пропущенных данных - ключевая задача при подготовке данных для анализа. В этом разделе рассмотрены три подхода: заполнение среднего значения, линейная интерполяция и заполнение медианным значением. Каждый из методов протестирован на данных о диаметре астероидов с искусственно созданными пропусками.

9.1 Описание методов

1. **Заполнение среднего значения:** Пропущенные значения заменяются средним значением всех доступных данных в столбце. Этот метод прост в реализации, но может быть неэффективен при наличии выбросов.
2. **Линейная интерполяция:** Метод предполагает линейное изменение между соседними известными значениями. Этот подход наиболее подходит для данных, которые изменяются плавно.
3. **Заполнение медианным значением:** Пропуски заполняются медианным значением всех имеющихся данных. Метод устойчив к выбросам и подходит для данных с асимметрией.

9.2 Результаты тестирования

Для оценки точности методов была рассчитана средняя ошибка восстановления пропусков. Результаты следующие:


- Среднее значение: 0.879
- Медиана: 0.86
- Линейная интерполяция: 0.0041 (наиболее точный метод)

На основе полученных результатов линейная интерполяция продемонстрировала наименьшую среднюю ошибку, что свидетельствует о её высокой точности в случае частых пропусков в наборе данных.


Заметим, что при более редких пропусках методы среднего значения и интерполяции будут приближаться к реальной плотности распределения данных.

9.3 Визуализация восстановления пропусков

Для наглядности результаты восстановления пропусков были визуализированы на графиках, построенных с использованием Python и R.



(a) Восстановление пропусков с использованием Python



(b) Восстановление пропусков с использованием R

Рис. 8: Графики восстановления пропусков методом линейной интерполяции.

9.4 Сравнение результатов между Python и R

Результаты восстановления пропусков, выполненные на Python и R, показали высокую согласованность, хотя и с небольшими различиями в точности. Оба языка подтвердили эффективность линейной интерполяции как наиболее точного метода:

- **Python:** линейная интерполяция - 0.0041 (наиболее точный метод)
- **R:** линейная интерполяция - 0.0027 (наиболее точный метод)

Метод линейной интерполяции в R показал несколько лучшую точность (0.0027 против 0.0041 в Python), что может быть связано с особенностями реализации алгоритма или численными методами. Оба языка продемонстрировали, что линейная интерполяция значительно превосходит методы заполнения средним значением и медианой.

Таким образом, метод линейной интерполяции рекомендован для использования в задачах восстановления пропусков в данных с плавными изменениями, при этом реализация в R показала слегка лучшие результаты.

10 Анализ данных с помощью графиков эмпирических функций распределений

10.1 Графики эмпирических функций распределений (ECDF)

Графики эмпирической функции распределения (Empirical Cumulative Distribution Function, ECDF) являются удобным инструментом для визуализации распределения данных. Они показывают накопленную вероятность того, что случайная величина примет значение меньше или равно заданному. Построение ECDF осуществляется следующим образом:

- Все значения выборки сортируются по возрастанию.
- Для каждого значения вычисляется доля элементов, которые меньше или равны этому значению.

- Результат отображается в виде ступенчатой линии, где каждая ступенька соответствует одному наблюдению.

ECDF предоставляет детальную информацию о распределении данных, позволяя выявить их центральные тенденции, отклонения и асимметрии. Этот график полезен для анализа данных независимо от их предполагаемого распределения.

10.1.1 Особенности ECDF

- **Гладкость:** Для больших выборок график становится более плавным за счёт увеличения числа наблюдений. Для малых выборок график будет ступенчатым.
- **Центр распределения:** Медиана выборки отображается в центре графика. Если данные симметричны, график будет относительно сбалансированным.
- **Поведение концов графика:** Низкие и высокие значения данных отображаются на концах графика. Для нормального распределения график плавно приближается к 1.
- **Влияние стандартного отклонения:** Чем больше стандартное отклонение, тем более растянутым становится график, так как данные распределяются на большем интервале.


10.2 Данные для анализа

Для анализа были сгенерированы выборки с использованием нормального распределения с различными параметрами:


- **data1:** 200 элементов, нормальное распределение, среднее 0, стандартное отклонение 1.
- **data2:** 200 элементов, нормальное распределение, среднее 0, стандартное отклонение 2.
- **data3:** 2000 элементов, нормальное распределение, среднее 0, стандартное отклонение 1.
- **data4:** 2000 элементов, нормальное распределение, среднее 2, стандартное отклонение 1.

10.3 Визуализация ECDF

На следующих графиках представлены эмпирические функции распределений для каждой из указанных выборок.



(а) График ECDF, построенный с использованием Python



(б) График ECDF, построенный с использованием R

Рис. 9: Сравнение графиков эмпирических функций распределения (ECDF), построенных с использованием Python и R.

10.4 Графики квантиль-квантиль (Q-Q Plots)


Графики квантиль-квантиль (Quantile-Quantile Plots, Q-Q Plots) являются мощным инструментом для анализа соответствия распределения данных теоретическому распределению. Они помогают визуально оценить, насколько данные соответствуют, например, нормальному, экспоненциальному или любому другому распределению.

10.4.1 Описание метода


Метод Q-Q Plot основывается на сравнении квантилей эмпирического распределения данных с квантилями заданного теоретического распределения:

- Квантили данных рассчитываются на основе их рангового распределения.
- Квантили теоретического распределения вычисляются для тех же процентилей, что и квантили данных.
- Наблюдаемые и теоретические квантили отображаются в виде точек на графике.

Если распределение данных совпадает с теоретическим, точки на графике будут лежать вдоль прямой линии, указывающей на соответствие. Отклонения от прямой линии свидетельствуют о нарушении предположений о распределении.



(a) Q-Q Plot, построенный с использованием Python



(b) Q-Q Plot, построенный с использованием R

Рис. 10: Сравнение Q-Q Plots, построенных с использованием Python и R, для проверки соответствия данных нормальному распределению.

10.4.2 Применение Q-Q Plots

Графики квантиль-квантиль широко применяются для:

- Проверки нормальности распределения данных перед статистическим анализом.
- Обнаружения выбросов или асимметрии в данных.
- Сравнения различных наборов данных или моделей распределения.

10.5 Заключение

На представленных Q-Q Plots (Python и R) точки графиков в основном располагаются вдоль прямой линии, что подтверждает соответствие данных нормальному распределению.

10.6 Метод огибающих

10.6.1 Теоретические основы


Метод огибающих применяется для анализа экстремальных значений в распределении данных. Он включает построение:

- **Верхней огибающей:** Кривая, соединяющая максимальные значения в данных.
- **Нижней огибающей:** Кривая, соединяющая минимальные значения в данных.


Этот метод позволяет изучать отклонения распределения данных от теоретической модели, выявлять тренды, выбросы и асимметрии.

10.6.2 Анализ данных с помощью огибающих

Для анализа с использованием метода огибающих были построены графики на основе данных, сгенерированных из нормальных распределений с различными параметрами. Графики были созданы с использованием Python и R.



(а) Огибающие, построенные с использованием Python



(б) Огибающие, построенные с использованием R

Рис. 11: Графики метода огибающих для анализа распределения данных.

10.6.3 Выводы и сравнение Python и R

Результаты, полученные с использованием Python и R, практически идентичны. Это объясняется использованием схожих алгоритмов для вычисления экстремальных значений и построения кривых.

10.6.4 Заключение

Метод огибающих является полезным инструментом для анализа распределения данных. Он наглядно демонстрирует влияние параметров распределения, таких как стандартное отклонение, на поведение данных. Сравнение Python и R показало, что оба инструмента предоставляют точные результаты, и выбор языка зависит от предпочтений пользователя и особенностей задачи.

11 Критерии проверки нормальности данных

В данном разделе представлены основные статистические тесты для проверки нормальности распределения данных, включая краткое теоретическое описание каждого метода.

11.1 Тест Шапиро-Уилка (и Шапиро-Франсиа)

Назначение: Проверка соответствия распределения данных нормальному закону распределения.

Формулировка гипотез:

- **Нулевая гипотеза (H):** Данные происходят из нормально распределенной генеральной совокупности.
- **Альтернативная гипотеза (H):** Данные не происходят из нормально распределенной генеральной совокупности.

Тестовая статистика:

- Для выборки $X_1, X_2, \dots, X_n$, упорядоченной по возрастанию: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$
- Статистика Шапиро-Уилка: $W = \frac{(\sum_{i=1}^n a_i X_{(i)})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$

- где a_i — константы, рассчитанные на основе ковариационной матрицы порядковых статистик стандартного нормального распределения
- $W \in [0, 1]$, причем значения, близкие к 1, свидетельствуют о нормальности распределения

Теоретическая основа: Тест оценивает линейность на графике квантиль-квантиль (Q-Q plot), измеряя корреляцию между выборочными квантилями данных и теоретическими квантилями нормального распределения.

Особенности:

- **Мощность теста:** Является одним из наиболее мощных тестов нормальности для выборок размером от 3 до 5000 наблюдений.
- **Область применения:**
 - Тест Шапиро-Уилка оптимален для малых и средних выборок (до 50 наблюдений)
 - Модификация Шапиро-Франсиа применяется для средних и больших выборок (от 50 до 5000 наблюдений)
- **Чувствительность:** Наиболее чувствителен к отклонениям от симметрии распределения, эффективен против альтернатив с асимметрией и эксцессом.

11.2 Тест Андерсона-Дарлинга

Назначение: Проверка соответствия распределения данных нормальному закону распределения.

Формулировка гипотез:

- **Нулевая гипотеза (H):** Данные происходят из нормально распределенной генеральной совокупности.
- **Альтернативная гипотеза (H):** Данные не происходят из нормально распределенной генеральной совокупности.

Тестовая статистика:

- Для выборки $X_1, X_2, \dots, X_n$, упорядоченной по возрастанию: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$
- Статистика Андерсона-Дарлинга: $A^2 = -n - \sum_{i=1}^n \frac{(2i-1)}{n} [\ln(F(Y_i)) + \ln(1 - F(Y_{n+1-i}))]$
- где $Y_i = \frac{X_{(i)} - \bar{X}}{s}$ — стандартизованные порядковые статистики,
- F — функция распределения стандартного нормального закона,
- $\bar{X}$ и s — выборочное среднее и стандартное отклонение.

Теоретическая основа: Тест оценивает взвешенные отклонения эмпирической функции распределения (ECDF) от теоретической нормальной функции распределения. Он придаёт больший вес отклонениям в хвостах распределения.

Особенности:

- **Чувствительность к хвостам:** Особо эффективен для обнаружения отклонений от нормальности в хвостах распределения.
- **Область применения:** Подходит для малых и средних выборок.
- **Критические значения:** Сравнение статистики A^2 производится с табличными критическими значениями для соответствующего уровня значимости.

11.3 Критерий Крамера-фон Мизеса

Назначение: Проверка соответствия распределения данных нормальному закону распределения.

Формулировка гипотез:

- **Нулевая гипотеза (H):** Данные происходят из нормально распределенной генеральной совокупности.
- **Альтернативная гипотеза (H):** Данные не происходят из нормально распределенной генеральной совокупности.

Тестовая статистика:

- Для выборки $X_1, X_2, \dots, X_n$, упорядоченной по возрастанию: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$
- Статистика Крамера-фон Мизеса: $W^2 = \frac{1}{12n} + \sum_{i=1}^n \left[F(Y_i) - \frac{2i-1}{2n} \right]^2$
- где $Y_i = \frac{X_{(i)} - \bar{X}}{s}$ — стандартизованные порядковые статистики,
- F — функция распределения стандартного нормального закона,
- $\bar{X}$ и s — выборочное среднее и стандартное отклонение.

Теоретическая основа: Тест оценивает согласованность эмпирической функции распределения (ECDF) с теоретической, суммируя квадрат отклонений между ними. Он особенно чувствителен к отклонениям в центральной части распределения.

Особенности:

- **Чувствительность:** Особо эффективен для обнаружения отклонений от нормальности в центральной части распределения.
- **Область применения:** Используется для малых и средних выборок.
- **Универсальность:** Более универсален по сравнению с другими тестами для данных со сложными распределениями.
- **Критические значения:** Сравнение статистики W^2 производится с табличными критическими значениями для соответствующего уровня значимости.

11.4 Тест Колмогорова-Смирнова

Назначение: Проверка соответствия распределения данных нормальному закону распределения.

Формулировка гипотез:

- **Нулевая гипотеза (H):** Данные происходят из нормально распределенной генеральной совокупности.
- **Альтернативная гипотеза (H):** Данные не происходят из нормально распределенной генеральной совокупности.

Тестовая статистика:

- Для выборки $X_1, X_2, \dots, X_n$, упорядоченной по возрастанию: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$
- Статистика Колмогорова-Смирнова: $D = \sup_x |F_n(x) - F(x)|$
- где $F_n(x)$ — эмпирическая функция распределения (ECDF),
- $F(x)$ — теоретическая нормальная функция распределения,
- $\sup$ — супремум (наибольшее отклонение).

Теоретическая основа: Тест проверяет нормальность, оценивая максимальное отклонение эмпирической функции распределения (ECDF) от теоретической функции. Он подходит для любых объёмов выборки и не предполагает каких-либо специфических параметров.

Особенности:

- **Интерпретация:** Прост в интерпретации.
- **Универсальность:** Универсален и применяется для различных типов распределений.
- **Чувствительность:** Чувствителен к отклонениям в хвостах распределения.
- **Критические значения:** Сравнение статистики D производится с табличными критическими значениями Колмогорова для соответствующего уровня значимости.

11.5 Модификация Лиллиефорса теста Колмогорова-Смирнова

Назначение: Проверка соответствия распределения данных нормальному закону распределения.

Формулировка гипотез:

- **Нулевая гипотеза (H):** Данные происходят из нормально распределенной генеральной совокупности.

- **Альтернативная гипотеза (H):** Данные не происходят из нормально распределенной генеральной совокупности.

Тестовая статистика:

- Статистика Лиллиефорса: $D = \sup_x |F_n(x) - \Phi(x; \hat{\mu}, \hat{\sigma}^2)|$
- где $F_n(x)$ — эмпирическая функция распределения (ECDF),
- $\Phi(x; \hat{\mu}, \hat{\sigma}^2)$ — теоретическая нормальная функция распределения с параметрами, оцененными по выборке,
- $\hat{\mu} = \bar{X}$ и $\hat{\sigma}^2 = s^2$ — выборочное среднее и дисперсия,
- $\sup$ — супремум (наибольшее отклонение).

Теоретическая основа: Это модификация теста Колмогорова-Смирнова, предназначенная для проверки нормальности данных. В отличие от оригинального теста, здесь параметры распределения (среднее и дисперсия) оцениваются непосредственно из выборки, что делает тест более адаптированным.

Особенности:

- **Адаптивность:** Учитывает реальные параметры распределения, что делает его подходящим для практических задач.
- **Область применения:** Эффективен для малых и средних выборок.
- **Критические значения:** Используются специальные критические значения Лиллиефорса, отличающиеся от стандартных значений Колмогорова-Смирнова.

11.6 Заключение

Каждый из перечисленных тестов имеет свои особенности и область применения. Выбор метода зависит от объема выборки, свойств данных (например, симметрия или наличие выбросов) и цели анализа.

12 Сравнение результатов проверки нормальности между Python и R

Для проверки нормальности распределения данных были проведены тесты на Python и R с использованием различных статистических критериев. Тесты проводились на данных, сгенерированных из нормальных распределений с различными параметрами: $N(0, 1)$, $N(0, 2)$, $N(2, 1)$, с объёмом выборки 200 и 2000 наблюдений.

12.1 Сводные результаты тестов

Тест	Распределение	Python, p-value	R, p-value	Результат
Колмогоров-Смирнов	$N(0, 1)$, 200	0.8146	0.8247	не отвергнуть
Колмогоров-Смирнов	$N(0, 2)$, 200	0.7545	0.8227	не отвергнуть
Колмогоров-Смирнов	$N(0, 1)$, 2000	0.6922	0.6183	не отвергнуть
Колмогоров-Смирнов	$N(2, 1)$, 2000	0.9202	0.5754	не отвергнуть
Шапиро-Уилк	$N(0, 1)$, 200	0.1989	0.7324	не отвергнуть
Шапиро-Уилк	$N(0, 2)$, 200	0.5628	0.2820	не отвергнуть
Шапиро-Уилк	$N(0, 1)$, 2000	0.7471	0.6029	не отвергнуть
Шапиро-Уилк	$N(2, 1)$, 2000	0.4869	0.4840	не отвергнуть
Андерсон-Дарлинг	$N(0, 1)$, 200	0.0600	0.3800	не отвергнуть
Андерсон-Дарлинг	$N(0, 2)$, 200	0.0600	0.3386	не отвергнуть
Андерсон-Дарлинг	$N(0, 1)$, 2000	0.0600	0.2147	не отвергнуть
Андерсон-Дарлинг	$N(2, 1)$, 2000	0.0600	0.5800	не отвергнуть
Крамер-фон Мизес	$N(0, 1)$, 200	0.8317	0.7705	не отвергнуть
Крамер-фон Мизес	$N(0, 2)$, 200	0.7719	0.8340	не отвергнуть
Крамер-фон Мизес	$N(0, 1)$, 2000	0.7354	0.8951	не отвергнуть
Крамер-фон Мизес	$N(2, 1)$, 2000	0.9177	0.9851	не отвергнуть
Лиллиефорс	$N(0, 1)$, 200	0.4522	0.4377	не отвергнуть
Лиллиефорс	$N(0, 2)$, 200	0.3758	0.4314	не отвергнуть
Лиллиефорс	$N(0, 1)$, 2000	0.2768	0.1899	не отвергнуть
Лиллиефорс	$N(2, 1)$, 2000	0.6669	0.8346	не отвергнуть
Шапиро-Франсиа	$N(0, 1)$, 200	0.1989	0.5212	не отвергнуть
Шапиро-Франсиа	$N(0, 2)$, 200	0.5628	0.3745	не отвергнуть
Шапиро-Франсиа	$N(0, 1)$, 2000	0.7471	0.4872	не отвергнуть
Шапиро-Франсиа	$N(2, 1)$, 2000	0.4869	0.3366	не отвергнуть

Таблица 2: Результаты тестов проверки нормальности для Python и R.

12.2 Выводы по результатам сравнения Python и R

- Во всех тестах результаты p -value как на Python, так и на R свидетельствуют об отсутствии оснований для отклонения гипотезы о нормальности данных.


- Различия в значениях p -value объясняются различиями в реализации статистических тестов и их численной аппроксимации в библиотеках Python и R. Однако эти различия не влияют на итоговые выводы.
- Python предоставляет удобные инструменты для быстрого выполнения тестов и анализа, в то время как R предлагает более широкий набор специализированных функций и параметров для работы с тестами.

Таким образом, оба языка успешно решают задачу проверки нормальности распределения, и выбор инструмента зависит от предпочтений пользователя и целей анализа.


13 Анализ реальных данных на нормальность

Для анализа реальных данных использовались графики эмпирической функции распределения (ECDF), квантиль-квантиль (Q-Q) графики и графики огибающих. Анализ проводился для параметров: качество вина, летучая кислотность, содержание алкоголя и остаточный сахар.

13.1 Графики эмпирической функции распределения (ECDF)




(a) ECDF для качества, летучей кислотности, алкоголя и сахара, построенные на Python




(b) ECDF для качества, летучей кислотности, алкоголя и сахара, построенные на R

Рис. 12: Графики ECDF для качества вина, летучей кислотности, содержания алкоголя и остаточного сахара.

13.2 Графики квантиль-квантиль (Q-Q Plots)




(a) Q-Q Plots для качества, летучей кислотности, алкоголя и сахара, построенные на Python




(b) Q-Q Plots для качества, летучей кислотности, алкоголя и сахара, построенные на R

Рис. 13: Графики квантиль-квантиль для качества вина, летучей кислотности, содержания алкоголя и остаточного сахара.

13.3 Графики огибающих



(a) Огибающие для качества, летучей кислотности, алкоголя и сахара, построенные на Python



(b) Огибающие для качества, летучей кислотности, алкоголя и сахара, построенные на R

Рис. 14: Графики огибающих для качества вина, летучей кислотности, содержания алкоголя и остаточного сахара.

Тест	Параметр	Python, p-value	R, p-value	Результат
Колмогоров-Смирнов	Качество вина	1.84×10^{-88}	0	отвергнута
Колмогоров-Смирнов	Крепость вина	4.99×10^{-21}	0	отвергнута
Колмогоров-Смирнов	Летучая кислотность	0.000133	0.000142	отвергнута
Колмогоров-Смирнов	Остаточный сахар	2.43×10^{-96}	0	отвергнута
Шапиро-Уилк	Качество вина	9.52×10^{-36}	0	отвергнута
Шапиро-Уилк	Крепость вина	6.64×10^{-27}	0	отвергнута
Шапиро-Уилк	Летучая кислотность	2.69×10^{-16}	0	отвергнута
Шапиро-Уилк	Остаточный сахар	1.02×10^{-52}	0	отвергнута
Андерсон-Дарлинг	Качество вина	0.04	0	отвергнута
Андерсон-Дарлинг	Крепость вина	0.04	0	отвергнута
Андерсон-Дарлинг	Летучая кислотность	0.04	0	отвергнута
Андерсон-Дарлинг	Остаточный сахар	0.04	0	отвергнута
Крамер-фон Мизес	Качество вина	9.71×10^{-10}	0	отвергнута
Крамер-фон Мизес	Крепость вина	4.91×10^{-10}	0	отвергнута
Крамер-фон Мизес	Летучая кислотность	0.0114	0	отвергнута
Крамер-фон Мизес	Остаточный сахар	1.38×10^{-8}	0	отвергнута
Лиллиефорс	Качество вина	0.001	0	отвергнута
Лиллиефорс	Крепость вина	0.001	0	отвергнута
Лиллиефорс	Летучая кислотность	0.001	0	отвергнута
Лиллиефорс	Остаточный сахар	0.001	0	отвергнута
Шапиро-Франсиа	Качество вина	9.52×10^{-36}	0	отвергнута
Шапиро-Франсиа	Крепость вина	6.64×10^{-27}	0	отвергнута
Шапиро-Франсиа	Летучая кислотность	2.69×10^{-16}	0	отвергнута
Шапиро-Франсиа	Остаточный сахар	1.02×10^{-52}	0	отвергнута

Таблица 3: Результаты тестов проверки нормальности данных на Python и R.

13.4 Различия между Python и R

Анализ нормальности данных был выполнен на Python и R с использованием различных статистических тестов. Основные наблюдения:

- В обоих языках тесты показывают идентичные результаты относительно принятия или отклонения гипотезы о нормальности данных - все параметры отклоняют гипотезу о нормальности.
- Незначительные различия наблюдаются в значениях p -value, что связано с различиями в численной реализации методов в Python и R. Например, тест Колмогорова-Смирнова в R для большинства параметров показывает p -value = 0, в то время как Python выдает крайне малые, но ненулевые значения.
- Наибольшее сходство результатов наблюдается для параметра "Летучая кислотность" где оба языка показывают близкие значения p -value в тесте Колмогорова-Смирнова (0.000133 в Python и 0.000142 в R).

13.5 Анализ нормальности данных

На основе результатов всех тестов можно сделать следующие выводы:

- Все четыре параметра (качество вина, крепость, летучая кислотность и остаточный сахар) не соответствуют нормальному распределению, так как p -value во всех тестах оказался значительно меньше порогового уровня значимости ($\alpha = 0.05$).
- Летучая кислотность является наиболее близкой к нормальному распределению среди исследованных параметров. Это видно по относительно более высоким значениям p -value в тестах Колмогорова-Смирнова (0.000133) и Крамера-фон Мизеса (0.0114) по сравнению с другими параметрами.
- Качество вина и остаточный сахар демонстрируют наибольшие отклонения от нормальности, что подтверждается экстремально низкими значениями p -value (порядка 10^{-36} - 10^{-96}) во всех тестах.
- Крепость вина также значительно отклоняется от нормального распределения, но в меньшей степени, чем качество и остаточный сахар.

13.6 Заключение

Результаты анализа показывают, что все исследуемые параметры вина не подчиняются нормальному распределению, хотя летучая кислотность демонстрирует распределение, наиболее близкое к нормальному. Это указывает на необходимость использования непараметрических методов или методов, устойчивых к ненормальности данных, при дальнейшем статистическом анализе характеристик вина. Особенно это важно для анализа качества вина и содержания остаточного сахара, которые показывают наибольшие отклонения от нормальности.

14 Проверка гипотез о средних значениях выборок с использованием критерия Стьюдента

14.1 Теоретические основы

Критерий Стьюдента предназначен для проверки гипотез о средних значениях двух выборок. Его основная цель — определить, является ли разница между средними значениями статистически значимой или случайной.

14.1.1 Нулевая и альтернативная гипотезы

- **Нулевая гипотеза (H_0):** Средние значения двух выборок равны ($\mu_1 = \mu_2$).
- **Альтернативная гипотеза (H_1):** Средние значения двух выборок различаются ($\mu_1 \neq \mu_2$ для двустороннего теста) или одно среднее больше/меньше другого ($\mu_1 < \mu_2$ или $\mu_1 > \mu_2$ для одностороннего теста).

14.1.2 Основные формулы

Для двух независимых выборок с равными дисперсиями:

t-статистика:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

где

- $\bar{X}_1, \bar{X}_2$ — выборочные средние
- n_1, n_2 — объёмы выборок
- s_p — объединённое стандартное отклонение:

$$s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

- s_1^2, s_2^2 — выборочные дисперсии

Степени свободы:

$$df = n_1 + n_2 - 2$$

Для случая неравных дисперсий (тест Уэлча):

t-статистика:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Степени свободы (приближение Уэлча-Саттертуэйта):

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$$

14.1.3 Условия применимости

Для корректного применения критерия Стьюдента должны выполняться следующие условия:

- Данные в выборках должны быть нормально распределены (или объём выборок достаточно велик для применения ЦПТ)
- Выборки должны быть независимыми
- Для классического t-теста: дисперсии двух выборок должны быть равными (гомоскедастичность)
- Для теста Уэлча: допускается неравенство дисперсий

14.1.4 Типы тестов

- **Двусторонний тест:** Проверяет, отличаются ли средние значения выборок в любом направлении ($H_1 : \mu_1 \neq \mu_2$)
- **Односторонний тест:** Проверяет, является ли одно среднее значение больше или меньше другого ($H_1 : \mu_1 < \mu_2$ или $H_1 : \mu_1 > \mu_2$)

14.1.5 Правило принятия решения

Результаты теста интерпретируются на основе значения p -value и уровня значимости α :

- Если $p\text{-value} < \alpha$ (обычно 0.05), то нулевая гипотеза (H_0) отвергается
- Если $p\text{-value} \geq \alpha$, то оснований для отклонения H_0 нет

Статистика t сравнивается с критическими значениями распределения Стьюдента с df степенями свободы.

14.2 Описание теста

Был проведён тест Стьюдента для проверки равенства средних значений двух выборок, сгенерированных из нормальных распределений. Параметры выборок: средние значения 10 и 30, стандартные отклонения 100 для обеих выборок, размер каждой выборки 100 наблюдений. Уровень значимости $\alpha = 0.1$. Рассмотрены как двусторонний, так и односторонний тесты.

14.3 Результаты тестов

- **Двусторонний тест:**
 - **Python:** $p\text{-value} = 0.0033$, гипотеза H_0 отвергается
 - **R:** $p\text{-value} = 0.9917$, гипотеза H_0 не отвергается
- **Односторонний тест ($\text{sample1} < \text{sample2}$):**
 - **Python:** $p\text{-value} = 0.9983$, гипотеза H_0 не отвергается
 - **R:** $p\text{-value} = 0.5042$, гипотеза H_0 не отвергается
- **Мощность теста:** 0.4080 для двустороннего и 0.5516 для одностороннего теста
- **Необходимый размер выборки** для достижения мощности 0.8: 309.79 для двустороннего и 225.81 для одностороннего теста

14.4 Сравнение результатов Python и R

- Наблюдаются значительные расхождения в результатах между Python и R, особенно в двустороннем тесте.
- В Python двусторонний тест показывает статистически значимое различие ($p\text{-value} = 0.0033$), тогда как в R различие незначимо ($p\text{-value} = 0.9917$).
- Значения t -статистики также существенно различаются: -2.9709 в Python против -0.0105 в R.
- Мощность теста и необходимый размер выборки идентичны в обоих языках, что свидетельствует о корректной реализации этих расчетов.
- Расхождения могут быть связаны с различиями в генерации случайных чисел или численных алгоритмах в библиотеках `scipy` (Python) и `stats` (R).

14.5 Выводы

Результаты теста Стьюдента показывают:

- Существуют значительные расхождения в результатах между Python и R, требующие дополнительного исследования причин.
- Текущая мощность теста ($0.408\text{--}0.552$) недостаточна для надежного обнаружения эффекта.
- Для достижения приемлемой мощности 0.8 требуется увеличение размера выборки до $226\text{--}310$ наблюдений.
- Односторонний тест в обоих языках не выявил статистически значимого различия между выборками.

15 Проверка гипотезы с использованием U-теста Манна-Уитни

15.1 Теоретические основы

U-тест Манна-Уитни (или тест Уилкоксона-Манна-Уитни) является непараметрическим методом для проверки гипотез о распределениях двух независимых выборок. Его основная цель — определить, является ли различие между распределениями двух групп статистически значимым, без предположения о нормальности данных.

15.1.1 Нулевая и альтернативная гипотезы

- **Нулевая гипотеза (H_0):** Распределения двух групп идентичны, то есть $P(X > Y) = P(Y > X)$.
- **Альтернативная гипотеза (H_1):** Распределения двух групп отличаются. Для двустороннего теста: $P(X > Y) \neq P(Y > X)$. Для одностороннего теста: $P(X > Y) > P(Y > X)$ или $P(X > Y) < P(Y > X)$.

15.1.2 Основные формулы

Для двух независимых выборок $X = \{x_1, \dots, x_m\}$ и $Y = \{y_1, \dots, y_n\}$:

Статистика U Манна-Уитни:

$$U_X = R_X - \frac{m(m+1)}{2}$$

$$U_Y = R_Y - \frac{n(n+1)}{2}$$

$$U = \min(U_X, U_Y)$$

где

- R_X — сумма рангов элементов выборки X в объединённой выборке
- R_Y — сумма рангов элементов выборки Y в объединённой выборке
- m, n — размеры выборок

Для больших выборок ($m, n > 20$):

$$z = \frac{U - \frac{mn}{2}}{\sqrt{\frac{mn(m+n+1)}{12}}}$$

где z приблизительно распределена по стандартному нормальному закону.

15.1.3 Условия применимости

Для корректного применения U-теста Манна-Уитни должны выполняться следующие условия:

- Выборки должны быть независимыми
- Данные измерены по крайней мере в порядковой шкале
- Распределения выборок имеют одинаковую форму (для проверки сдвига медиан)
- Не требуется предположение о нормальности распределения
- Допускается наличие связей (ties) в данных

15.1.4 Типы тестов

- **Двусторонний тест:** Проверяет, отличаются ли распределения двух групп в любом направлении
- **Односторонний тест:** Проверяет, сдвинуто ли распределение одной группы относительно другой в определённом направлении

15.1.5 Правило принятия решения

Результаты теста интерпретируются на основе значения p -value и уровня значимости α :

- Если $p\text{-value} < \alpha$ (обычно 0.05), то нулевая гипотеза (H_0) отвергается
- Если $p\text{-value} \geq \alpha$, то оснований для отклонения H_0 нет

Для малых выборок статистика U сравнивается с табличными критическими значениями Манна-Уитни. Для больших выборок используется нормальное приближение.

15.2 Описание анализа

Были проведены два теста Манна-Уитни для анализа качества вина:

- **Тест 1:** Сравнение двух случайно сформированных выборок из общего набора данных о вине.
- **Тест 2:** Сравнение качества вина между группами с низким и высоким содержанием алкоголя. Группы были разделены по медиане содержания алкоголя.

15.3 Результаты тестов

- **Результаты теста 1 (случайные выборки):**
 - Python: $U = 5023.5$, $p = 0.9515$
 - R: $U = 5461.0$, $p = 0.2231$
 - Результат: В обоих случаях нет оснований отклонить нулевую гипотезу (H_0), что ожидаемо, так как выборки взяты из одной генеральной совокупности.
- **Результаты теста 2 (низкий vs высокий алкоголь):**
 - Python: $U = 2828.5$, $p = 1.20 \times 10^{-8}$
 - R: $U = 3205.5$, $p = 1.88 \times 10^{-6}$
 - Результат: В обоих языках нулевая гипотеза (H_0) отвергается, существуют статистически значимые различия в качестве вина между группами с разным содержанием алкоголя.

15.4 Сравнение Python и R

- В обоих тестах Python и R показывают одинаковые выводы о принятии или отклонении нулевой гипотезы.

- Наблюдаются различия в значениях статистики U и p -value, что может быть связано с:
 - Различиями в алгоритмах генерации случайных чисел при создании выборок
 - Особенности численных методов вычислений в библиотеках `scipy` (Python) и `stats` (R)
 - Разными подходами к обработке связок (ties) в данных
- Несмотря на численные различия, качественные выводы тестов полностью совпадают в обоих языках.

15.5 Выводы

- Результаты U-теста Манна-Уитни подтверждают, что случайные выборки из данных о вине имеют идентичные распределения качества.
- Обнаружены статистически значимые различия в качестве вина между группами с низким и высоким содержанием алкоголя.
- Вина с более высоким содержанием алкоголя демонстрируют лучшее качество, что подтверждается крайне низкими p -value в обоих тестах.
- Использование Python и R для проведения теста Манна-Уитни даёт согласованные качественные выводы, подтверждая надёжность метода на обеих платформах.

16 Проверка гипотез об однородности дисперсий с использованием различных критериев

16.1 Теоретические основы

Проверка однородности дисперсий является важным этапом статистического анализа, особенно при сравнении нескольких групп данных. Цель

данной проверки — определить, являются ли дисперсии в сравниваемых группах статистически одинаковыми, что является ключевым предположением для многих параметрических тестов, таких как ANOVA и t-тест.

16.1.1 Нулевая и альтернативная гипотезы

Для всех критериев проверки однородности дисперсий:

- **Нулевая гипотеза (H_0):** Дисперсии во всех группах равны ($\sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$).
- **Альтернативная гипотеза (H_1):** По крайней мере две группы имеют различные дисперсии.

16.1.2 Основные критерии и их формулы

В данном исследовании были использованы четыре критерия:

1. Критерий Левене

$$W = \frac{(N - k)}{(k - 1)} \cdot \frac{\sum_{i=1}^k n_i (Z_{i.} - Z_{..})^2}{\sum_{i=1}^k \sum_{j=1}^{n_i} (Z_{ij} - Z_{i.})^2}$$

где

- $Z_{ij} = |X_{ij} - \tilde{X}_i|$ — абсолютное отклонение от медианы группы i
- $\tilde{X}_i$ — медиана группы i
- n_i — размер группы i
- k — количество групп
- N — общий объём выборки

Распределение: $W \sim F(k - 1, N - k)$

2. Критерий Бартлетта

$$\chi^2 = \frac{(N - k) \ln(s_p^2) - \sum_{i=1}^k (n_i - 1) \ln(s_i^2)}{1 + \frac{1}{3(k-1)} \left(\sum_{i=1}^k \frac{1}{n_i - 1} - \frac{1}{N - k} \right)}$$

где

- s_i^2 — дисперсия группы i
- $s_p^2 = \frac{\sum_{i=1}^k (n_i - 1) s_i^2}{N - k}$ — объединённая дисперсия

Распределение: $\chi^2 \sim \chi^2(k - 1)$

3. Критерий Флигнера-Килина

$$\chi^2 = \frac{\sum_{i=1}^k n_i (\bar{R}_i - \bar{R})^2}{\frac{1}{N-1} \sum_{i=1}^k \sum_{j=1}^{n_i} (R_{ij} - \bar{R})^2}$$

где

- R_{ij} — ранг абсолютного отклонения $|X_{ij} - \tilde{X}_i|$
- $\bar{R}_i$ — средний ранг в группе i
- $\bar{R}$ — общий средний ранг

Распределение: $\chi^2 \sim \chi^2(k - 1)$

4. Критерий Фишера (F-тест для двух выборок)

$$F = \frac{s_1^2}{s_2^2}$$

где s_1^2 и s_2^2 — выборочные дисперсии двух групп. Распределение: $F \sim F(n_1 - 1, n_2 - 1)$

16.1.3 Условия применимости и особенности

- **Критерий Левене:** Устойчив к отклонениям от нормальности. Рекомендуется для данных с нарушенной нормальностью распределения.
- **Критерий Бартлетта:** Чувствителен к нарушению нормальности распределения. Требует нормальности данных.
- **Критерий Флигнера-Килина:** Непараметрический аналог критерия Левене, использующий ранги данных. Устойчив к выбросам и не требует нормальности.
- **Критерий Фишера:** Применяется только для сравнения двух выборок и предполагает нормальность распределения.

16.1.4 Правило принятия решения

Для всех критериев:

- Если $p\text{-value} < \alpha$ (обычно 0.05), то отвергаем H_0 (дисперсии неоднородны)
- Если $p\text{-value} \geq \alpha$, то не отвергаем H_0 (дисперсии можно считать однородными)

16.2 Результаты тестов

16.2.1 Сравнение выборок с равными дисперсиями

Были сгенерированы две выборки объёмом 50 наблюдений из нормального распределения с одинаковым стандартным отклонением = 10.

Критерий	Статистика	р-значение
Левене	0.278272	0.599029
Бартлетта	0.209028	0.647531
Флигнера-Килина	0.464430	0.495561
Фишера	1.140355	0.647538

Таблица 4: Результаты для равных дисперсий на Python.

R:

Критерий	Статистика	р-значение
Левене	1.798428	0.183003
Бартлетта	2.308512	0.128667
Флигнера-Килина	2.414866	0.120188
Фишера	1.549682	0.128669

Таблица 5: Результаты для равных дисперсий на R.

Интерпретация: Все критерии в обеих реализациях показали $p\text{-value} > 0.05$, что указывает на отсутствие статистически значимых различий между дисперсиями. Это корректный результат, так как выборки были сгенерированы с одинаковыми дисперсиями.

16.2.2 Сравнение выборок с различными дисперсиями

Для проверки чувствительности критериев сравнивались выборки со средними квадратичными отклонениями 10 и 15 (объём 50 наблюдений).

Критерий	Статистика	p-значение
Левене	9.042786	0.003351
Бартлетта	11.181186	0.000826
Флигнера-Килина	8.535369	0.003483
Фишера	0.375766	0.000826

Таблица 6: Результаты для различных дисперсий на Python.

R:

Критерий	Статистика	p-значение
Левене	0.704681	0.403259
Бартлетта	1.726736	0.188828
Флигнера-Килина	0.417848	0.518013
Фишера	0.684905	0.188833

Таблица 7: Результаты для различных дисперсий на R.

Интерпретация: В Python все критерии показали p-значение < 0.05 , что правильно указывает на наличие значимых различий между дисперсиями. В R все критерии, напротив, не выявили значимых различий ($p > 0.05$), что не соответствует действительности.

16.3 Сравнение реализаций в Python и R

- **Равные дисперсии:** Обе среды показали согласованные результаты - отсутствие значимых различий между дисперсиями.
- **Различные дисперсии:** Наблюдается существенное расхождение. Python корректно детектировал различия, в то время как R во всех тестах показал отсутствие значимых различий, что может указывать на различия в алгоритмах или методах расчёта.

- **Чувствительность критериев:** В Python критерии Бартлетта и Фишера показали наименьшие р-значения (0.000826), что свидетельствует об их высокой чувствительности к различиям в дисперсиях при нормальном распределении данных.

16.4 Выводы

- Все рассмотренные критерии корректно работают при проверке однородности дисперсий в случае их равенства.
- При наличии различий в дисперсиях реализация критериев в Python показала более высокую чувствительность и точность по сравнению с R.
- Наиболее чувствительными к различиям в дисперсиях оказались критерии Бартлетта и Фишера, однако они требуют соблюдения предположения о нормальности распределения.
- Критерии Левене и Флигнера-Килина продемонстрировали сбалансированные результаты как для равных, так и для неравных дисперсий, что делает их предпочтительными при отклонениях от нормальности.
- Обнаруженные расхождения между Python и R подчеркивают важность проверки и верификации статистических методов в разных программных средах.

17 Корреляционные взаимосвязи в данных о качестве вина

17.1 Теоретические основы

Корреляционный анализ позволяет исследовать взаимосвязи между переменными и определять силу и направление этих связей. Цель данного анализа — выявление статистически значимых ассоциаций между показателями качества вина, такими как общая оценка качества, содержание алкоголя и уровень летучей кислотности.

Поскольку распределения переменных качества вина, летучей кислотности и содержания алкоголя статистически значимо отличаются от нормального распределения (что подтверждено тестами нормальности), параметрический коэффициент корреляции Пирсона в данном исследовании неприменим. Вместо него используются непараметрические методы, не требующие предположения о нормальности.

17.1.1 Нулевая и альтернативная гипотезы

Для коэффициентов корреляции:

- **Нулевая гипотеза (H_0):** Между переменными нет статистически значимой корреляции ($\rho = 0$).
- **Альтернативная гипотеза (H_1):** Между переменными существует статистически значимая корреляция ($\rho \neq 0$).

17.1.2 Основные коэффициенты и их формулы

В исследовании использовались два непараметрических метода:

1. Коэффициент корреляции Спирмена (ρ_s или r_s)

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

где

- $d_i = R(x_i) - R(y_i)$ — разность рангов i -й пары наблюдений
- $R(x_i), R(y_i)$ — ранги значений переменных X и Y
- n — количество наблюдений

Особенности: Оценивает монотонную зависимость на основе рангов данных. Устойчив к выбросам и не требует предположения о нормальности.

2. Коэффициент корреляции Кендалла (τ)

$$\tau = \frac{n_c - n_d}{\frac{1}{2}n(n - 1)}$$

где

- n_c — количество согласованных пар (конкордантных)
- n_d — количество несогласованных пар (дискордантных)
- $\frac{1}{2}n(n-1)$ — общее количество возможных пар

Особенности: Более устойчив к ошибкам в данных и связям (ties), предпочтителен при небольших выборках. Интерпретируется как вероятность того, что порядок пар согласован.

17.1.3 Условия применимости и особенности

- **Коэффициент Спирмена:** Требуется, чтобы данные были измерены как минимум в порядковой шкале. Эффективен для обнаружения монотонных зависимостей.
- **Коэффициент Кендалла:** Также требует порядковой шкалы. Менее чувствителен к экстремальным значениям, чем Спирмен, но может давать более низкие значения при наличии множественных связей в данных.
- **Общее:** Оба метода не требуют предположения о нормальности распределения и линейности связи.

17.1.4 Интерпретация значений коэффициентов

Значения коэффициентов интерпретируются следующим образом:

- от 0.00 до ± 0.29 — слабая корреляция
- от ± 0.30 до ± 0.69 — умеренная корреляция
- от ± 0.70 до ± 1.00 — сильная корреляция

Знак коэффициента указывает на направление связи: положительный — прямая зависимость, отрицательный — обратная зависимость.

17.1.5 Правило принятия решения

Результаты корреляционного анализа интерпретируются на основе значения p -value и уровня значимости α :

- Если $p\text{-value} < \alpha$ (обычно 0.05), то отвергаем H_0 (корреляция статистически значима)
- Если $p\text{-value} \geq \alpha$, то не отвергаем H_0 (корреляция статистически незначима)

17.2 Результаты корреляционного анализа

17.2.1 Результаты Python

Метод	Параметры	Quality	Alcohol	Volatile Acidity
Spearman	Quality	1.000000	0.478532	-0.380647
	Alcohol	0.478532	1.000000	-0.224932
	Volatile Acidity	-0.380647	-0.224932	1.000000
Kendall	Quality	1.000000	0.380367	-0.300779
	Alcohol	0.380367	1.000000	-0.151839
	Volatile Acidity	-0.300779	-0.151839	1.000000

Таблица 8: Коэффициенты корреляции, рассчитанные на Python.

17.2.2 Результаты R

Метод	Параметры	Quality	Alcohol	Volatile Acidity
Spearman	Quality	1.0000000	0.4785317	-0.3806465
	Alcohol	0.4785317	1.0000000	-0.2249317
	Volatile Acidity	-0.3806465	-0.2249317	1.0000000
Kendall	Quality	1.0000000	0.3803673	-0.3007787
	Alcohol	0.3803673	1.0000000	-0.1518387
	Volatile Acidity	-0.3007787	-0.1518387	1.0000000

Таблица 9: Коэффициенты корреляции, рассчитанные на R.

17.3 Сравнение результатов Python и R

- Результаты корреляционного анализа, выполненного на Python и R, демонстрируют полное совпадение с точностью до 6-7 знаков после запятой, что подтверждает идентичность математических алгоритмов в обеих платформах.
- Наибольшая корреляция наблюдается между качеством вина и содержанием алкоголя:
 - Коэффициент Спирмена: 0.4785 (умеренная положительная связь)
 - Коэффициент Кендалла: 0.3804 (умеренная положительная связь)

Это указывает на существенное влияние содержания алкоголя на оценку качества вина.

- Наблюдается умеренная отрицательная корреляция между летучими кислотами и качеством вина:
 - Коэффициент Спирмена: -0.3806 (умеренная отрицательная связь)
 - Коэффициент Кендалла: -0.3008 (слабая-умеренная отрицательная связь)

Это подтверждает, что летучая кислотность является важным дескриптором качества вина, причём более высокие значения кислотности ассоциированы с более низкими оценками качества.

- Слабая отрицательная корреляция обнаружена между содержанием алкоголя и летучей кислотностью:
 - Коэффициент Спирмена: -0.2249 (слабая отрицательная связь)
 - Коэффициент Кендалла: -0.1518 (очень слабая отрицательная связь)
- Все выявленные корреляции являются статистически значимыми ($p < 0.001$), что делает их полезными для построения моделей прогнозирования качества вина.

- Сравнение методов показывает, что коэффициенты Спирмена и Кендалла дают качественно согласованные результаты по направлению связи, но различаются по величине (Спирмен показывает более сильные связи). Это объясняется разной математической природой методов: коэффициент Кендалла более чувствителен к наличию связей (ties) в данных, особенно для переменной quality, которая имеет дискретную шкалу оценок.

17.4 Выводы

На основании проведённого корреляционного анализа были сделаны следующие выводы:

- Обнаружена умеренная положительная корреляция между содержанием алкоголя и качеством вина (0.4785 по Спирмену, 0.3804 по Кендаллу), что свидетельствует о важности этого параметра для оценки качества.
- Выявлена умеренная отрицательная корреляция между летучими кислотами и качеством вина (-0.3806 по Спирмену, -0.3008 по Кендаллу), подтверждающая негативное влияние повышенной кислотности на восприятие качества.
- Слабая отрицательная корреляция между алкоголем и летучими кислотами (-0.2249 по Спирмену, -0.1518 по Кендаллу) указывает на незначительную взаимосвязь этих параметров.
- Результаты обоих непараметрических методов корреляции (Спирмена и Кендалла) качественно согласуются между собой по направлению связей, что подтверждает надежность полученных результатов. Различие в величине коэффициентов объясняется особенностями методов и структурой данных.
- Полное совпадение результатов между Python и R демонстрирует корректность реализации алгоритмов в обеих платформах и воспроизводимость анализа.
- Полученные результаты подтверждают, что для анализа взаимосвязей в данных о качестве вина корректно использовать непараметрические методы корреляции, так как распределения исследуемых переменных отклоняются от нормального.

18 Различные методы анализа данных

В данном разделе описаны четыре метода анализа данных: критерий хи-квадрат, точный тест Фишера, тест МакНемара и тест Кохрана-Мантеля-Хензеля. Эти методы используются для анализа зависимости между категориальными переменными и проверки гипотез.

18.1 Критерий хи-квадрат

Критерий хи-квадрат (χ^2) используется для проверки гипотезы о независимости категориальных переменных. Он основывается на сравнении наблюдаемых и ожидаемых частот в таблице сопряжённости.

18.1.1 Основные гипотезы

- H_0 : Переменные независимы.
- H_1 : Переменные связаны.

18.1.2 Формула

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

где O_{ij} - наблюдаемая частота, E_{ij} - ожидаемая частота.

18.1.3 Применимость

- Требуется, чтобы ожидаемые частоты не были слишком малы (обычно $E_{ij} \geq 5$).
- Применим только для данных, где переменные имеют категориальную природу.

18.2 Точный тест Фишера

Точный тест Фишера используется для анализа таблиц сопряжённости размером 2×2 , особенно при небольших выборках. Этот тест вычисляет вероятность распределения данных при условии выполнения нулевой гипотезы.

18.2.1 Основные гипотезы

- H_0 : Переменные независимы.
- H_1 : Переменные связаны.

18.2.2 Особенности

- Не требует больших выборок и может быть применён даже при малых ожидаемых частотах.
- Основан на вычислении точных вероятностей, что делает его более точным, чем критерий хи-квадрат для небольших данных.

18.3 Тест МакНемара

Тест МакНемара используется для проверки изменений категориальных переменных в связанных выборках. Он анализирует данные в таблицах 2×2 , где сравниваются пары наблюдений (до и после).

18.3.1 Основные гипотезы

- H_0 : Изменений в распределении переменных нет.
- H_1 : Есть значимые изменения в распределении переменных.

18.3.2 Формула

$$\chi^2 = \frac{(b - c)^2}{b + c}$$

где b и c - частоты наблюдений, где произошли изменения.

18.3.3 Применимость

- Используется для парных данных.
- Часто применяется для анализа эффективности лечения, до- и посттестов, а также других случаев, где данные связаны.

18.4 Тест Кохрана-Мантеля-Хензеля

Тест Кохрана-Мантеля-Хензеля используется для анализа зависимостей между двумя категориальными переменными, контролируя влияние третьей переменной (стратификация).

18.4.1 Основные гипотезы

- H_0 : Отношение шансов одинаково во всех группах (стратах).
- H_1 : Отношение шансов различается между группами.

18.4.2 Формула

Тест основан на таблице сопряжённости для каждой группы (страты). Итоговая статистика агрегирует информацию из всех групп.

18.4.3 Применимость

- Используется для анализа связи между двумя переменными при наличии стратификационной переменной.
- Подходит для больших выборок и случаев, когда эффект третьей переменной может искажать результаты.

18.5 Проверка зависимости между содержанием алкоголя и летучей кислотностью с использованием критерия хи-квадрат

18.5.1 Описание исследования

Целью исследования была проверка гипотезы о наличии зависимости между содержанием алкоголя в вине и уровнем летучей кислотности. Для этого использовался критерий хи-квадрат.

Категоризация данных

- Содержание алкоголя было разделено на две категории:
 - **High Alc**: Алкоголь выше медианы

- **Low Alc:** Алкоголь ниже медианы
- Летучая кислотность была разделена на три категории:
 - **Low Acid:** Ниже первого терциля
 - **Medium Acid:** Между первым и вторым терцилем
 - **High Acid:** Выше второго терциля

18.5.2 Результаты теста

Для анализа была построена таблица сопряжённости:

	Low Acid	Medium Acid	High Acid
High Alc	353	260	190
Low Alc	202	280	314

Таблица 10: Таблица сопряжённости для категорий алкоголя и летучей кислотности.

Результаты теста хи-квадрат:

- **Python:**
 - Статистика хи-квадрат: 72.3023
 - p -значение: 1.99×10^{-16}
 - Степени свободы: 2
- **R:**
 - Статистика хи-квадрат: 72.3023
 - p -значение: 1.99×10^{-16}
 - Степени свободы: 2

18.5.3 Выводы

- Нулевая гипотеза (H_0) об отсутствии зависимости между содержанием алкоголя и летучей кислотностью отвергается, так как p -значение значительно меньше 0.05.

- Между содержанием алкоголя и летучей кислотностью существует сильная статистически значимая зависимость.
- **Интерпретация:** Вина с высоким содержанием алкоголя чаще ассоциируются с низкой и средней кислотностью, в то время как вина с низким содержанием алкоголя преобладают в категории высокой кислотности. Это соответствует ожидаемой физико-химической зависимости в виноделии.

18.6 Проверка зависимости между качеством вина и остаточным сахаром с использованием точного теста Фишера

18.6.1 Описание исследования

Целью исследования была проверка гипотезы о наличии зависимости между качеством вина и содержанием остаточного сахара на выборке из 100 объектов.

Категоризация данных

- Качество вина разделено на две категории:
 - **High Quality:** Качество выше медианы
 - **Low Quality:** Качество ниже медианы
- Остаточный сахар разделен на две категории:
 - **High Sugar:** Сахар выше медианы
 - **Low Sugar:** Сахар ниже медианы

18.6.2 Результаты теста

Для анализа были построены таблицы сопряжённости:

	High Sugar	Low Sugar
High Quality	25	27
Low Quality	25	23

Таблица 11: Таблица сопряжённости для категорий качества вина и остаточного сахара (Python).

	High Sugar	Low Sugar
High Quality	49	45
Low Quality	5	1

Таблица 12: Таблица сопряжённости для категорий качества вина и остаточного сахара (R).

Результаты точного теста Фишера:

- **Python:**

- Отношение шансов (Odds Ratio): 0.8519
- p -значение: 0.8415

- **R:**

- Отношение шансов (Odds Ratio): 0.2206
- p -значение: 0.2137

18.6.3 Анализ различий между Python и R

Различия в результатах обусловлены различиями в работе генераторов случайных чисел при создании тестовой выборки:

- Python и R используют разные алгоритмы для генерации случайных чисел, что влияет на распределение объектов между категориями.
- Таблицы сопряжённости отличаются по числам, что приводит к расхождениям в p -значениях и отношениях шансов.
- Несмотря на различия, оба результата показывают $p > 0.05$, что позволяет сделать одинаковый вывод об отсутствии статистически значимой зависимости.

18.6.4 Выводы

- Нулевая гипотеза (H_0) об отсутствии зависимости между качеством вина и остаточным сахаром не отвергается.
- Статистически значимой зависимости между качеством вина и остаточным сахаром не обнаружено.
- **Интерпретация:** Качество вина не зависит от содержания остаточного сахара в данной выборке. Это может свидетельствовать о том, что другие параметры (кислотность, алкоголь, танины) оказывают большее влияние на восприятие качества.

18.7 Проверка зависимости между качеством вина и содержанием алкоголя с использованием теста МакНемара

18.7.1 Описание исследования

Целью исследования была проверка зависимости между качеством вина и содержанием алкоголя в категориальном представлении. Для анализа использовался тест МакНемара.

Категоризация данных

- Качество вина разделено на две категории:
 - **High Quality:** Качество выше медианы
 - **Low Quality:** Качество ниже медианы
- Содержание алкоголя разделено на две категории:
 - **High Alcohol:** Алкоголь выше медианы
 - **Low Alcohol:** Алкоголь ниже медианы

18.7.2 Результаты теста

Для анализа были построены таблицы сопряжённости:

	High Alcohol	Low Alcohol
High Quality	34	18
Low Quality	11	37

Таблица 13: Таблица сопряжённости для теста МакНемара (Python).

	High Alcohol	Low Alcohol
High Quality	44	50
Low Quality	3	3

Таблица 14: Таблица сопряжённости для теста МакНемара (R).

Результаты теста МакНемара:

- **Python:**

- Статистика теста: 11.0000
- p -значение: 0.2649

- **R:**

- Статистика теста: 39.9245
- p -значение: < 0.0001

18.7.3 Выводы

- В Python p -значение > 0.05 - нет оснований отвергать нулевую гипотезу об отсутствии изменений.
- В R p -значение < 0.05 - есть статистически значимые изменения между категориями.
- **Интерпретация:** Противоречивые результаты между платформами требуют дополнительного исследования. Возможные причины расхождений - разные методы стратификации данных или различия в алгоритмах реализации теста.

18.8 Стратифицированный анализ связи с использованием теста Кохрана-Мантеля-Хензеля

18.8.1 Описание исследования

Анализ связи между содержанием алкоголя и остаточного сахара с учётом стратификации по категориям качества вина.

18.8.2 Результаты теста

- Python:

- Статистика CMH: 0.718
- p -значение: 0.397

- R:

- Статистика CMH: 1.526
- p -значение: 0.217

18.8.3 Выводы

- В обеих реализациях p -значение > 0.05 .
- Нет статистически значимой связи между содержанием алкоголя и остаточного сахара при контроле качества вина.
- **Интерпретация:** Качество вина не является confounding-фактором в отношении связи между алкоголем и остаточным сахаром. Это означает, что связь между этими двумя переменными (или её отсутствие) сохраняется независимо от уровня качества вина.

18.9 Общие выводы

- Обнаружена сильная статистически значимая зависимость между содержанием алкоголя и летучей кислотностью ($p < 0.001$).
- Не выявлено значимой связи между качеством вина и остаточным сахаром ($p > 0.05$).

- Результаты теста МакНемара показали противоречия между Python и R, что требует дополнительной проверки и валидации методов.
- Стратифицированный анализ подтвердил отсутствие связи между алкоголем и остаточным сахаром при контроле качества вина.
- Все методы демонстрируют хорошую согласованность между Python и R, за исключением теста МакНемара, где наблюдаются значительные расхождения.

18.10 Стратифицированный анализ связи между алкоголем и остаточным сахаром с использованием теста Кохрана-Мантеля-Хензеля

18.10.1 Описание исследования

Целью исследования было выявление связи между содержанием алкоголя и остаточным сахаром при учёте стратификации по качеству вина.

Категоризация данных

- **Содержание алкоголя:**
 - **High Alc:** Алкоголь выше медианы
 - **Low Alc:** Алкоголь ниже медианы
- **Остаточный сахар:**
 - **High Sugar:** Сахар выше медианы
 - **Low Sugar:** Сахар ниже медианы
- **Качество вина:**
 - Стратификационная переменная, разделённая на категории High Quality и Low Quality

18.10.2 Результаты теста

Результаты теста Кохрана-Мантеля-Хензеля:

- **Python:**
 - Статистика СМН: 0.718
 - p -значение: 0.397
- **R:**
 - Статистика СМН: 1.526
 - p -значение: 0.217

18.10.3 Выводы

- Нулевая гипотеза (H_0) об отсутствии связи между содержанием алкоголя и остаточным сахаром при всех уровнях качества вина не отвергается ($p > 0.05$).
- Статистически значимой связи между алкоголем и остаточным сахаром не обнаружено даже при учёте стратификации по качеству.
- **Интерпретация:** Отсутствие связи между содержанием алкоголя и остаточным сахаром подтверждается на всех уровнях качества вина. Это свидетельствует о том, что эти два параметра являются независимыми характеристиками вина, не влияющими друг на друга в рамках данной выборки.

19 Проверка наличия мультиколлинеарности в данных о вине

19.1 Методы анализа

Для проверки мультиколлинеарности были использованы:

- Корреляционная матрица, позволяющая оценить линейные зависимости между переменными.
- Фактор инфляции дисперсии (VIF), который показывает степень зависимости каждой переменной от других.

19.2 Фактор инфляции дисперсии (VIF)

Фактор инфляции дисперсии является мерой мультиколлинеарности, показывающей, насколько дисперсия коэффициента регрессии увеличивается из-за корреляции с другими предикторами.

19.2.1 Расчёт VIF

Для каждого предиктора X_j коэффициент VIF вычисляется как:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

где R_j^2 — коэффициент детерминации регрессионной модели, в которой переменная X_j является зависимой переменной, а все остальные предикторы — независимыми переменными.

19.2.2 Интерпретация значений


- **VIF = 1:** Полное отсутствие мультиколлинеарности
- **$1 < \text{VIF} \leq 5$:** Умеренная мультиколлинеарность, обычно приемлемая
- **$5 < \text{VIF} \leq 10$:** Высокая мультиколлинеарность, требует внимания
- **$\text{VIF} > 10$:** Серьёзная мультиколлинеарность, требует корректировки модели

19.2.3 Преимущества и ограничения


- **Преимущества:** Позволяет количественно оценить степень мультиколлинеарности для каждого предиктора
- **Ограничения:** Не учитывает возможные нелинейные зависимости между переменными

19.3 Корреляционная матрица

На рисунках представлены корреляционные матрицы, построенные в Python и R:



Корреляционная матрица, построенная на Python



Корреляционная матрица, построенная на R

Рис. 15: Корреляционные матрицы для анализа зависимости переменных в данных о вине.

19.4 Фактор инфляции дисперсии (VIF)

Переменная	VIF (Python)	VIF (R)	Статус
fixed acidity	7.77	7.77	Внимание
volatile acidity	1.88	1.88	Норма
citric acid	3.13	3.13	Норма
residual sugar	1.70	1.70	Норма
chlorides	1.50	1.50	Норма
free sulfur dioxide	1.97	1.97	Норма
total sulfur dioxide	2.21	2.21	Норма
density	6.35	6.35	Внимание
pH	3.34	3.34	Норма
sulphates	1.49	1.49	Норма
alcohol	3.24	3.24	Норма
quality	1.56	1.56	Норма

Таблица 15: Фактор инфляции дисперсии (VIF) для переменных вина, рассчитанный на Python и R.

19.5 Анализ результатов

- **Переменные с потенциальной мультиколлинеарностью:**
 - **Fixed acidity** (VIF = 7.77) - умеренно высокое значение, требует внимания
 - **Density** (VIF = 6.35) - умеренно высокое значение, требует внимания
- **Переменные без проблем мультиколлинеарности:**
 - Остальные переменные имеют значения VIF ниже 5, что указывает на отсутствие серьёзных проблем с мультиколлинеарностью
 - Наименьшие значения VIF у sulphates (1.49), chlorides (1.50) и quality (1.56)

19.6 Выводы

- В данных о вине обнаружена умеренная мультиколлинеарность для переменных **fixed acidity** и **density**. Это может быть связано с тем, что плотность вина часто коррелирует с содержанием кислот и других растворённых веществ.
- Остальные химические параметры вина демонстрируют низкие значения VIF, что свидетельствует об их относительной независимости в модели.
- Переменная **quality** имеет низкий VIF (1.56), что подтверждает её пригодность для использования в качестве зависимой переменной в регрессионных моделях.
- Результаты, полученные на Python и R, полностью совпадают, что подтверждает корректность расчётов в обеих средах.
- Для улучшения моделей рекомендуется рассмотреть возможность исключения или преобразования переменных с высокими значениями VIF, особенно при построении множественных регрессионных моделей.

19.7 Рекомендации

- При построении регрессионных моделей следует учитывать умеренную мультиколлинеарность между **fixed acidity** и **density**.
- Для более точного анализа можно рассмотреть использование главных компонент (PCA) или ридж-регрессии для обработки мультиколлинеарности.
- Переменные с низкими значениями VIF могут быть безопасно использованы в многомерном анализе без риска серьёзных искажений результатов.

20 Анализ влияния содержания алкоголя на физические свойства вина

20.1 Дисперсионный анализ (ANOVA)

20.1.1 Теоретические основы

Дисперсионный анализ (ANOVA) представляет собой статистический метод, предназначенный для проверки гипотезы о равенстве средних значений нескольких групп. Основная цель ANOVA — определить, оказывает ли категориальный фактор (группирующая переменная) статистически значимое влияние на количественную зависимую переменную.

20.1.2 Нулевая и альтернативная гипотезы

Для однофакторного дисперсионного анализа:

- **Нулевая гипотеза (H_0):** Все групповые средние равны ($\mu_1 = \mu_2 = \dots = \mu_k$)
- **Альтернативная гипотеза (H_1):** По крайней мере одно групповое среднее отличается от остальных

20.1.3 Основные формулы

F-статистика ANOVA:

$$F = \frac{MS_{\text{между}}}{MS_{\text{внутри}}} = \frac{SS_{\text{между}}/(k-1)}{SS_{\text{внутри}}/(N-k)}$$

где:

- $SS_{\text{между}} = \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2$ — сумма квадратов между группами
- $SS_{\text{внутри}} = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$ — сумма квадратов внутри групп
- $MS_{\text{между}} = SS_{\text{между}}/(k-1)$ — межгрупповой средний квадрат
- $MS_{\text{внутри}} = SS_{\text{внутри}}/(N-k)$ — внутригрупповой средний квадрат
- k — количество групп

- n_i — размер i -й группы
- N — общее количество наблюдений
- $\bar{X}_i$ — среднее значение i -й группы
- $\bar{X}$ — общее среднее

Степени свободы:

- Межгрупповые: $df_{\text{между}} = k - 1$
- Внутригрупповые: $df_{\text{внутри}} = N - k$
- Общие: $df_{\text{общие}} = N - 1$

20.1.4 Условия применимости

Для корректного применения классического ANOVA должны выполняться следующие условия:

- **Нормальность распределения:** Данные в каждой группе должны быть нормально распределены
- **Гомогенность дисперсий:** Дисперсии во всех группах должны быть равными
- **Независимость наблюдений:** Наблюдения в разных группах должны быть независимыми

20.1.5 Интерпретация результатов

- **F-статистика:** Показывает отношение межгрупповой изменчивости к внутригрупповой
- **p-value:** Вероятность получить наблюдаемые различия между группами при условии, что H_0 верна
- **Правило принятия решения:** Если $p\text{-value} < \alpha$ (обычно 0.05), отвергаем H_0

20.1.6 Описание исследования

В данном исследовании дисперсионный анализ был применён для изучения влияния содержания алкоголя на физические свойства вина. Выборка была разделена на четыре категории по содержанию алкоголя: 8-10%, 10-12%, 12-14% и 14-16%. Зависимой переменной анализа являлась плотность вина (density).

20.1.7 Модификации ANOVA

При нарушении предположений могут использоваться альтернативные методы:

- **ANOVA по Уэлчу:** Для случаев с неравными дисперсиями
- **Критерий Крускала-Уоллиса:** Непараметрическая альтернатива
- **Поправки:** Поправки Гринхауса-Гейсера или Хюина-Фельдта для повторных измерений

20.1.8 Результаты теста

Параметр	Python	R
F-статистика	137.91	137.91
P-значение	1.93×10^{-79}	1.93×10^{-79}

Таблица 16: Результаты дисперсионного анализа (ANOVA)

20.1.9 Выводы

- Высокое значение F-статистики (137.91) свидетельствует о наличии существенных различий в средней плотности вин между различными алкогольными категориями.
- Экстремально низкое p-value (1.93×10^{-79}) значительно ниже общепринятого уровня значимости 0.05, что даёт основание отвергнуть нулевую гипотезу о равенстве средних значений плотности во всех группах.

- Статистический анализ подтверждает, что категоризация вин по содержанию алкоголя позволяет выделить группы с достоверно различными показателями плотности.
- Наблюдается чёткая физико-химическая закономерность: увеличение концентрации алкоголя, имеющего меньшую плотность по сравнению с водой, приводит к снижению общей плотности вина.
- Результаты, полученные на Python и R, полностью идентичны, что подтверждает корректность проведения анализа в обеих средах.

21 Аппроксимация данных с использованием регрессионных моделей

21.1 Описание исследования

Для анализа зависимости между качеством вина и химическими параметрами были построены две регрессионные модели:

- Линейная регрессия
- Полиномиальная регрессия степени 3

Для оценки качества моделей использовались следующие метрики:

- R^2 (коэффициент детерминации): Показывает долю объяснённой дисперсии
- MSE (среднеквадратическая ошибка): Оценивает среднюю ошибку модели

21.2 Результаты анализа

Модель	Python	R
Линейная регрессия		
R^2	0.3619	0.3888
MSE	0.4170	0.4251
Полиномиальная регрессия (степень 3)		
R^2	0.3404	0.3784
MSE	0.4310	0.4323

Таблица 17: Результаты регрессионного анализа, выполненного на Python и R

21.3 Выводы

- **Сравнение моделей:**

- В отличие от ожиданий, полиномиальная модель степени 3 уступает линейной модели по всем метрикам как на Python, так и на R.
- Линейная модель демонстрирует более высокие значения R^2 и более низкие значения MSE в обеих средах.
- Низкие значения R^2 (< 0.4) обеих моделей свидетельствуют о слабой объясняющей способности и требуют применения других подходов к моделированию данных.

- **Сравнение результатов Python и R:**

- Результаты линейной регрессии показывают близкие значения: Python ($R^2 = 0.3619$, $MSE = 0.4170$) и R ($R^2 = 0.3888$, $MSE = 0.4251$).
- Для полиномиальной регрессии также наблюдаются схожие результаты: Python ($R^2 = 0.3404$, $MSE = 0.4310$) и R ($R^2 = 0.3784$, $MSE = 0.4323$).
- Небольшие различия могут быть связаны с особенностями реализации алгоритмов и методами оптимизации в разных средах.

- **Заключение:**

- Линейная регрессия показала себя более эффективной для описания зависимости качества вина от химических параметров.
- Низкая объясняющая способность моделей указывает на сложный, многомерный характер зависимости качества вина, который не может быть адекватно описан простыми регрессионными моделями.
- Для улучшения предсказательной способности рекомендуется рассмотреть более сложные модели, такие как случайные леса или градиентный бустинг, а также включить взаимодействия между переменными.

22 Общее сравнение Python и R

22.1 Общие наблюдения

В ходе проведённого анализа были использованы Python и R для выполнения различных статистических и регрессионных методов. Основные выводы о сравнении языков:

- **Схожие результаты:** Большинство анализов, включая дисперсионный анализ, корреляционный анализ, проверку гипотез и регрессионное моделирование, дали практически идентичные результаты на Python и R. Это подтверждает, что оба языка обеспечивают высокую точность и надёжность вычислений.
- **Небольшие различия:** В некоторых случаях, таких как регрессионный анализ, наблюдались незначительные отличия в метриках качества моделей. Эти различия обусловлены особенностями реализации алгоритмов и численных методов в Python и R.
- **Удобство использования:** Python предоставляет более лаконичный и интуитивно понятный синтаксис. Код в Python проще писать и читать, особенно для пользователей, не имеющих глубокого опыта работы с R.

- **Гибкость R:** Несмотря на менее удобный синтаксис, R предоставляет широкий спектр специализированных пакетов и инструментов, что делает его мощным инструментом для сложного статистического анализа.

22.2 Заключение

Python и R - мощные инструменты для анализа данных. Выбор языка зависит от конкретных задач и предпочтений пользователя. Для большинства пользователей Python станет предпочтительным выбором благодаря простоте синтаксиса и гибкости. Однако, для специфических статистических задач R остаётся сильным конкурентом.

Список литературы

- [1] Мاستицкий С.Э., Шитиков В.К. Статистический анализ и визуализация данных с помощью R. – М.: ДМК Пресс, 2015. – 496 с.
- [2] Брюс П., Брюс Э., Гедек П. Практическая статистика для специалистов Data Science. – 2-е изд., перераб. и доп. – СПб.: БХВ-Петербург, 2021. – 352 с.
- [3] Нильсен Э. Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение. – СПб.: ООО «Диалектика», 2021. – 544 с.